

Wprowadzenie do sztucznej inteligencji - ćwiczenie 5

Studenci

Bartłomiej Krawczyk
310774

Mateusz Brzozowski
310608

Zadanie:

Proszę zaimplementować perceptron dwuwarstwowy i nauczyć go reprezentować funkcję $J : [-5, 5] \rightarrow \mathbb{R}$, daną wzorem:

$$J(x) = \sin(x * \sqrt{p[0] + 1}) + \cos(x * \sqrt{p[1] + 1})$$

gdzie $p[0]$ i $p[1]$ to najmłodsze cyfry numerów indeksów wykonawców.

W sprawozdaniu powinny znaleźć się wykresy funkcji aproksymowanej i jej aproksymacji. Powinny również znaleźć się wskaźniki jakości aproksymacji.

Pytania:


Jak liczba neuronów w warstwie ukrytej wpływa na jakość aproksymacji?

Odpowiedzi

- funkcja czerwona - funkcja aproksymowana
- funkcja niebieska - funkcja aproksymacji

Parametry dla najlepszego wyniku:

- liczba neuronow: 13
- Liczba epok: 5000
- rozmiar mini zbioru: 100
- learning rate: 0.1




1. Wpływ liczby neuronów w warstwie ukrytej na jakość aproksymacji

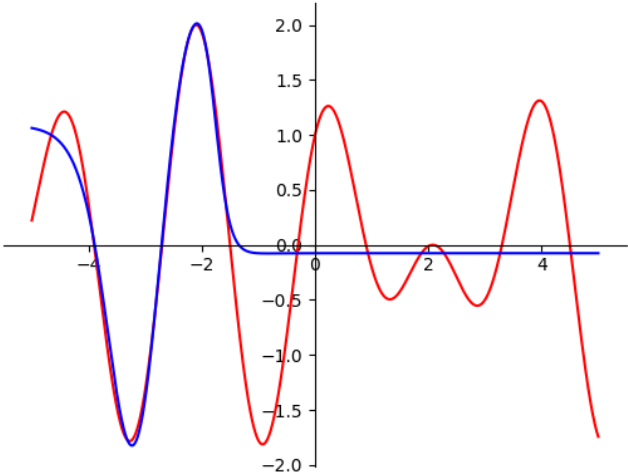
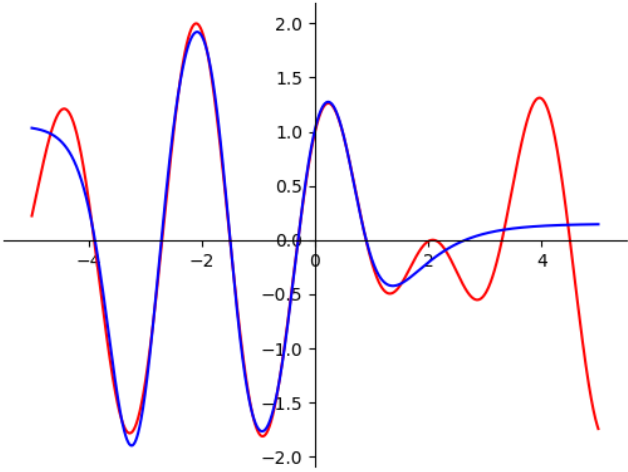
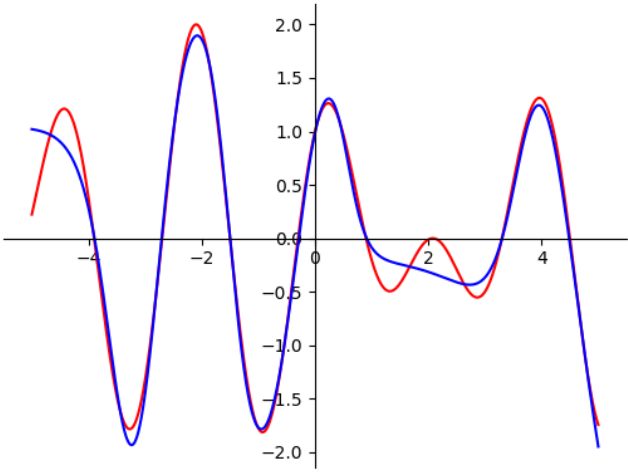
Parametry:

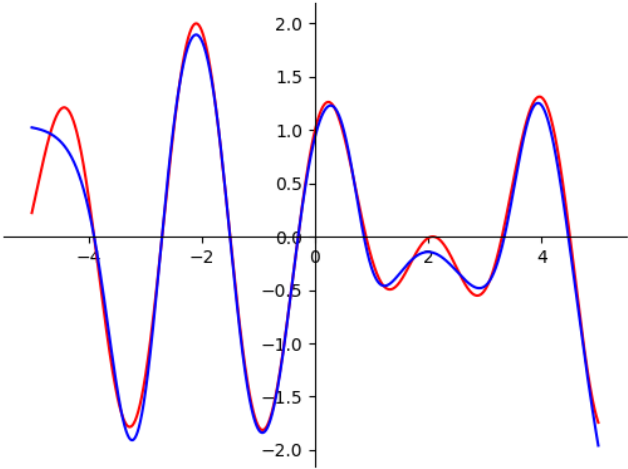
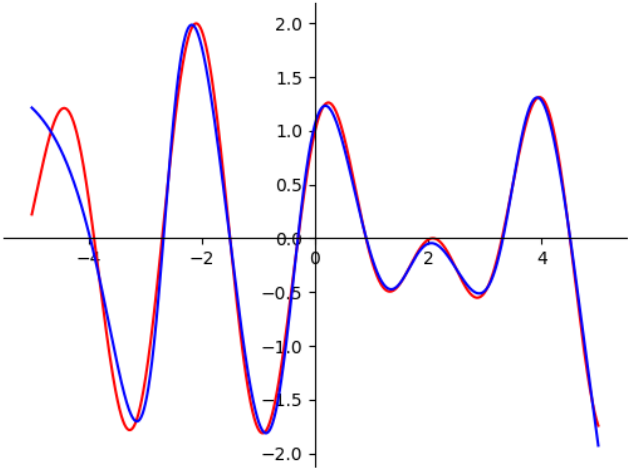
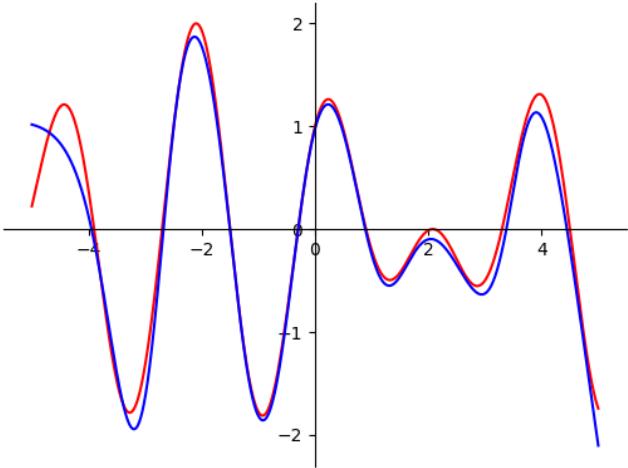
- Liczba epok: 1000
- rozmiar mini zbioru: 200
- learning rate: 0.1

I. neuronów	jakość aproksymacji	wykres
----------------	---------------------	--------

1	0.9626108158771487
---	--------------------



I. neuronów	jakość aproksymacji	wykres
3	0.5052205935619043	
6	0.20932076027426308	
9	0.028579552869285273	

I. neuronów	jakość aproksymacji	wykres
13	0.02101232492836344	
20	0.04631622547961368	
50	0.026904497018995624	

Jak widzimy kiedy zwiększamy liczbę neuronów w warstwie ukrytej, to zwiększa się jakość aproksymacji. Dla niewielkich wartości 1,3,6,9, przy zwiększaniu liczby neuronów jakość aproksymacji się poprawia w sposób znaczący. Jednakże po osiągnięciu najlepszej jakości, nie następuje dalsze polepszanie się wyniku, wręcz przeciwnie jesteśmy w stanie zauważyć pogorszenie się jakości wyników. Tak więc, im więcej nie oznacza lepiej, należy dobrać odpowiednią liczbę, nie za dużą, tak żeby nie wysyąpił efekt przeuczenia, ale też i nie za małą.


2. Wpływ liczby epok na jakość aproksymacji

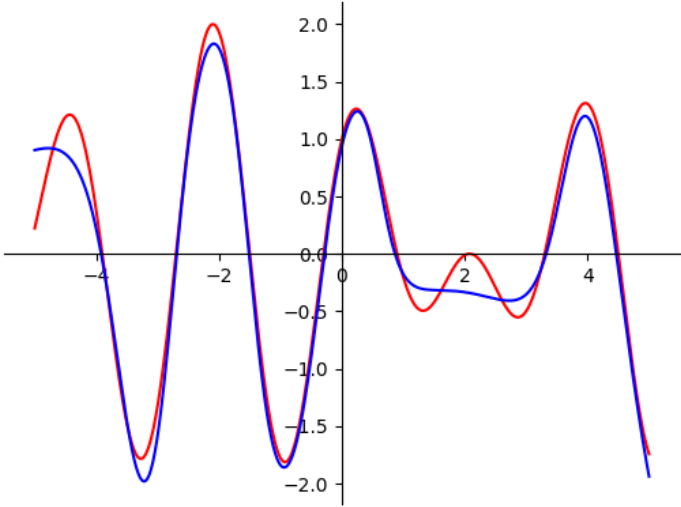
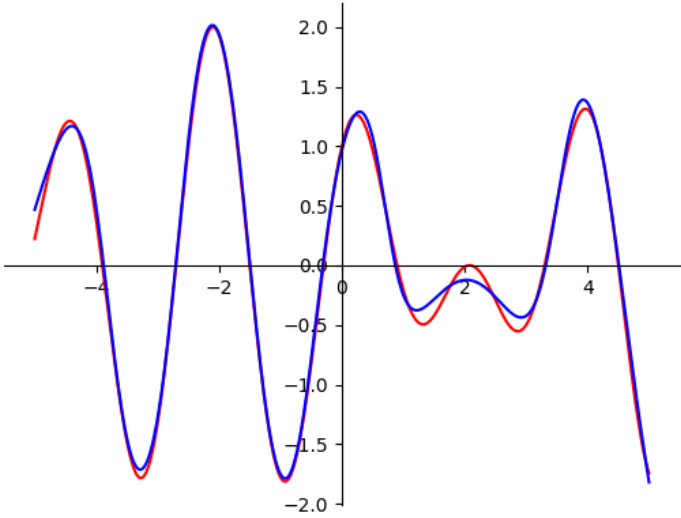
Parametry:

- liczba neuronow: 13
- rozmiar mini zbioru: 100
- learning rate: 0.1

I. epok	jakość aproksymacji	wykres
---------	---------------------	--------


100	0.6036005131793474
-----	--------------------



I. epok	jakość aproksymacji	wykres
500	0.025507866058764903	
1000	0.003881639756722564	

I. epok	jakość aproksymacji	wykres
------------	---------------------	--------


2500	0.000464653486408472
------	----------------------



3000	0.000371961012552506
------	----------------------

4000	0.000710141625934429
------	----------------------

5000	0.000500152100903829
------	----------------------

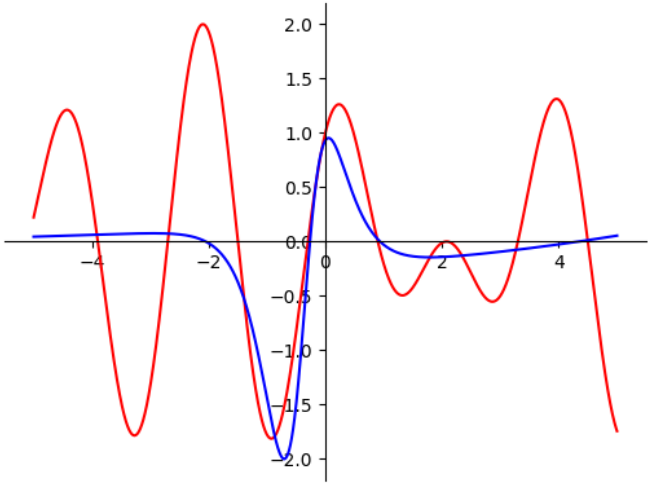
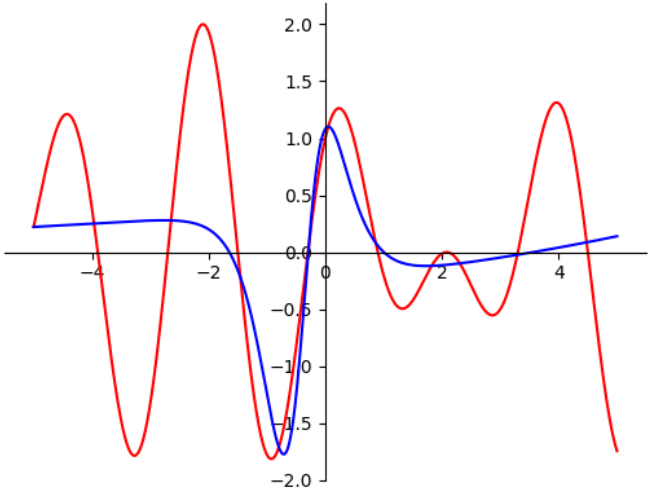


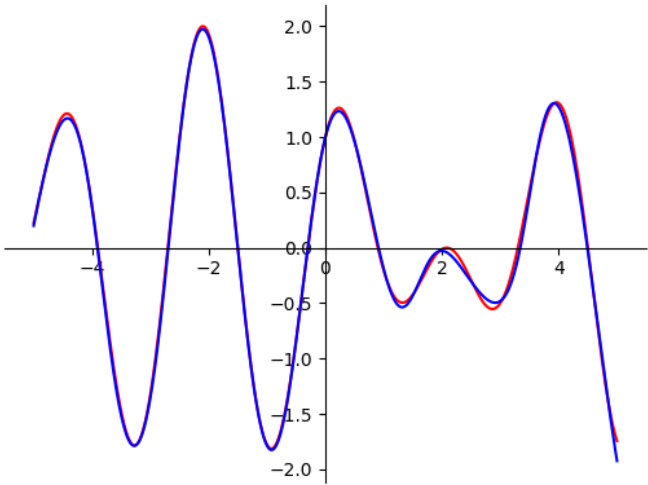
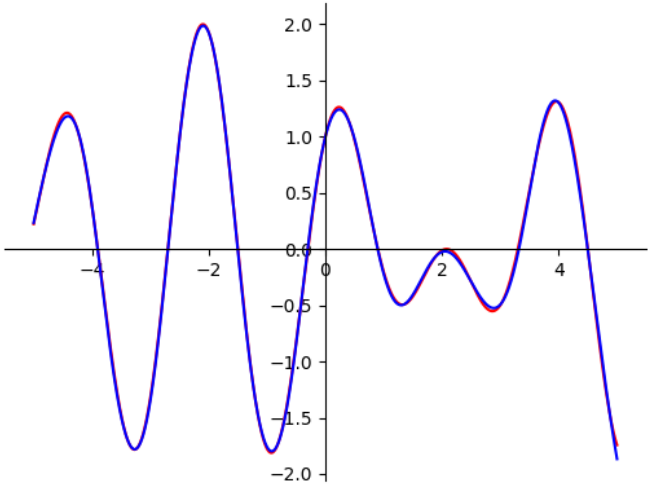
Jak widzimy w tym przypadku im więcej tym lepiej, jednakże po przekroczeniu pewnego progu wyniki, nie ulegają poprawie, tylko utrzymują się na pewnym poziomie jakości aproksymacji.

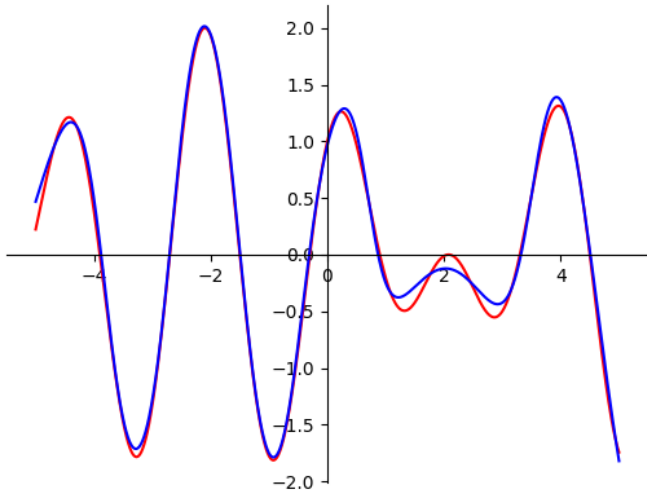
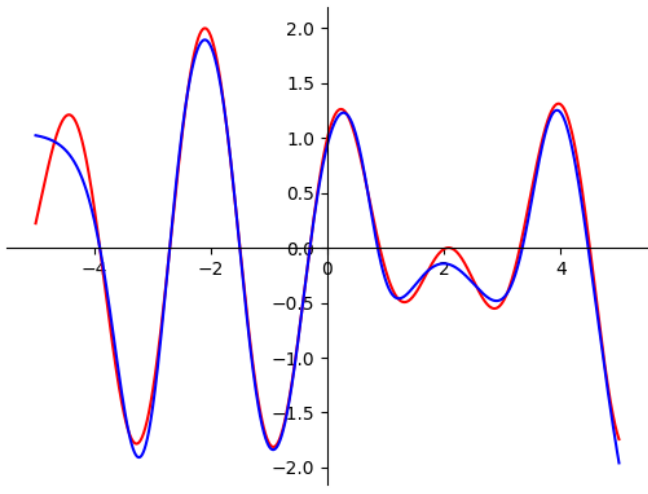
3. Wpływ rozmiaru mini zbioru na jakość aproksymacji

Parametry:

- liczba neuronów: 13
- Liczba epok: 1000
- learning rate: 0.1

r. min zbioru	jakość aproksymacji	wykres
5	0.742208769993701	
10	0.7329583312672093	

r. min zbioru	jakość aproksymacji	wykres
25	0.00146432025873798	
50	0.000609914994377384	

r. min zbioru	jakość aproksymacji	wykres
100	0.005854738926109195	
200	0.02101232492836344	

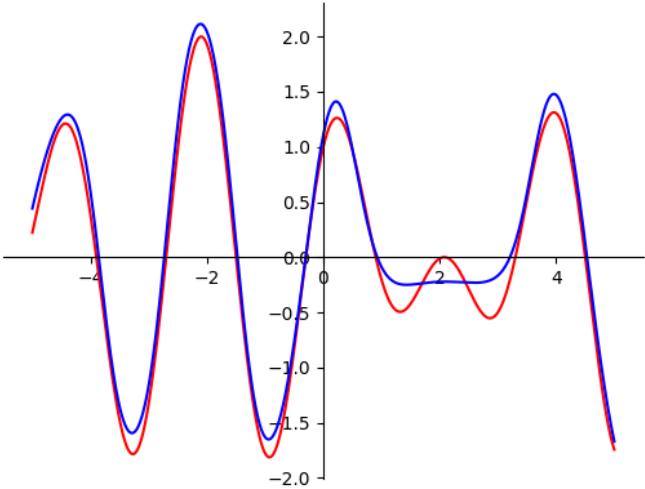
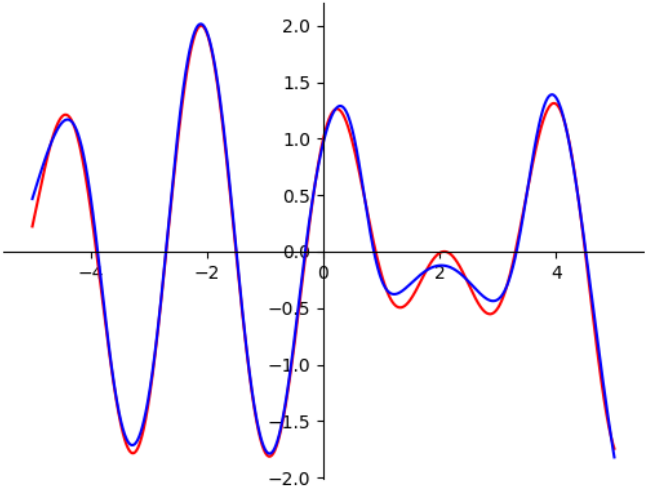
Dla poszczególnych parametrów musimy odnaleźć odpowiedni rozmiar mini zbioru, ponieważ za duży rozmiar lub za mały, negatywnie wpływa na jakość aproksymacji.

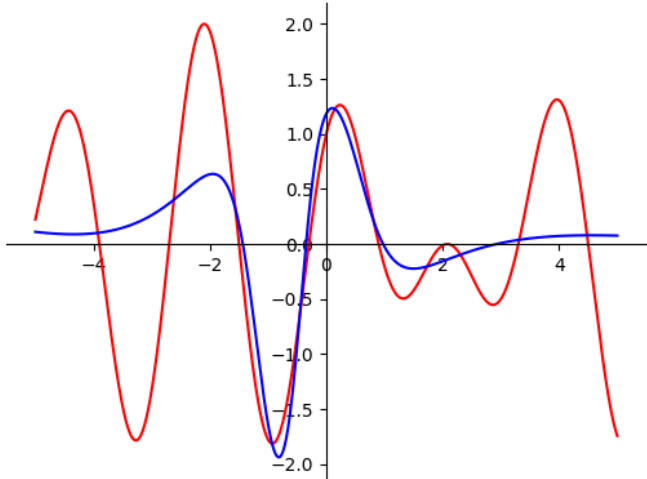
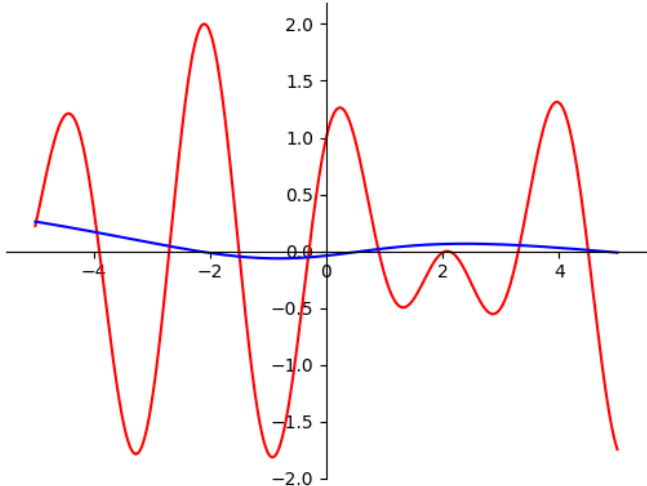
4. Wpływ learning rate na jakość aproksymacji

Parametry:

- liczba neuronów: 13
- Liczba epok: 1000
- rozmiar zbioru: 100

learning rate	jakość aproksymacji	wykres
------------------	---------------------	--------

learning rate	jakość aproksymacji	wykres
0.2	0.01651475725734568	
0.1	0.005854738926109195	

learning rate	jakość aproksymacji	wykres
0.01	0.6692954914503615	
0.001	0.985174553192548	

Im mniejszy learning rate, tym mniejsza jakość aproksymacji, jednakże jest to spowodowane tym, że na stałym poziomie pozostają inne parametry i w teorii powinna nam się zwiększać dokładność, ponieważ robimy małe, bardziej dokładne skoki, ale żeby taki stan osiągnąć powinniśmy znacząco zwiększyć liczbę epok.